

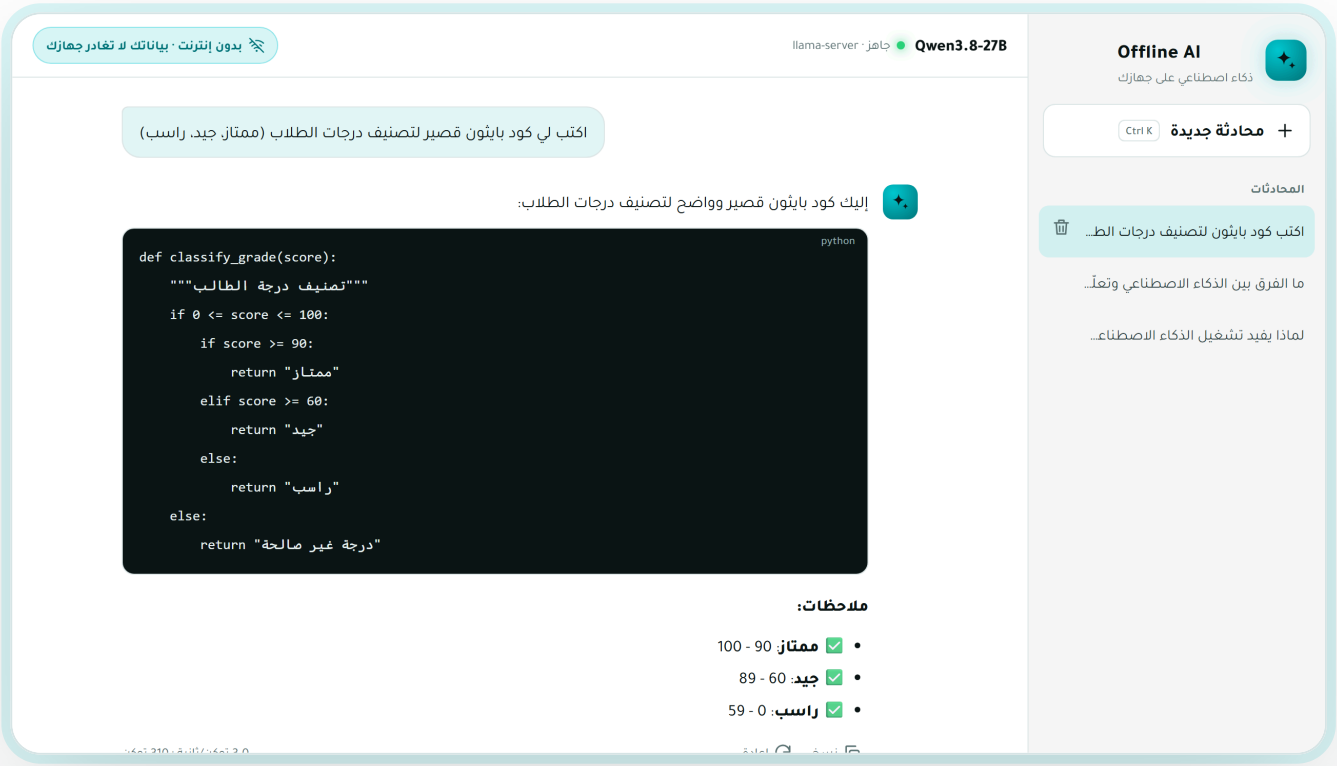
محمد مهدي

Offline AI

دليل التشغيل خطوة بخطوة

شغّل نموذج ذكاء اصطناعي متقدّمًا على جهازك، دون اتصال بالإنترنت، ودون اشتراك، ودون الحاجة إلى أي خبرة تقنية.

دون إنترنت | مجاني بالكامل | نماذج Qwen · Google · OpenAI | يدعم العربية



إعداد وتصميم: محمد مهدي

طالب هندسة ذكاء اصطناعي

Instagram · @mo.79u

WhatsApp · +964 783 853 3230

قبل البدء

ما هو Offline AI؟

يتيح لك Offline AI التحدث مع نموذج ذكاء اصطناعي (مثل ChatGPT) **يعمل على جهازك مباشرةً**. وتختار بنفسك النموذج الذي يناسب جهازك، من نموذج خفيف يعمل على أبسط الحواسيب إلى نموذج قوي للأجهزة المتقدمة. وبعد تنزيله مرة واحدة يعمل دون إنترنت، ولا تغادر محادثاتك جهازك أبدًا.

📋 المتطلبات

العنصر	الحد المطلوب
نظام التشغيل	Windows 10 أو Windows 11
الذاكرة (RAM)	من **4 GB** إلى **32 GB** حسب النموذج الذي تختاره (صفحة 5)
بطاقة الرسوميات	غير مطلوبة للنماذج الصغيرة، ومستحسنة (NVIDIA) للنماذج الكبيرة
المساحة الفارغة	من 2 GB إلى 25 GB حسب النموذج
الإنترنت	مرة واحدة فقط لتنزيل البرنامج والنموذج

💡 **كيف أعرف حجم الذاكرة في جهازي؟** اضغط Esc + Shift + Ctrl معًا لفتح **Task Manager**، ثم انتقل إلى تبويب **Performance** واختر **Memory**؛ الرقم الكبير في الأعلى هو حجم الذاكرة.

🗺️ محتويات الدليل

★	تعرّف على نماذج Qwen	صفحة 3
1	تثبيت برنامج Ollama	صفحة 4
2	اختيار النموذج المناسب لجهازك (Qwen و Google و OpenAI) وتنزيله	صفحة 5
3	تنزيل الواجهة من GitHub	صفحة 7
4	تشغيل الواجهة على نموذجك	صفحة 8
5	طريقة الاستخدام والتبديل بين النماذج	صفحة 9
⚡	اجعل النموذج أسرع، وطريقة التشغيل بالنقر المزدوج	صفحة 10
؟	حل المشكلات والأسئلة الشائعة	صفحة 11

📋 **يمكنك نسخ أي أمر في هذا الدليل مباشرةً:** حدّده بالفأرة داخل المربع، ثم اضغط Ctrl + C للنسخ، و Ctrl + V للصق.

ولفتح أي رابط في تبويب جديد دون إغلاق هذا الدليل، اضغط Ctrl أثناء النقر على الرابط.

★ تعرّف على النماذج

نماذج Qwen: العقل الذي يعمل على جهازك

جميع النماذج في هذا الدليل من عائلة **Qwen** التي يطوّرها **فريق Qwen التابع لشركة Alibaba Cloud** (مجموعة علي بابا)، وهي نماذج مفتوحة المصدر تتراوح أحجامها بين نموذج صغير يعمل على أبسط الحواسيب، ونماذج كبيرة تقترب من أداء الخدمات السحابية. وإلى جانبها يدعم المشروع نماذج من Google وOpenAI (صفحة 5).

من 0.8 إلى 35 مليار
معامل (Parameters)

المعاملات هي القيم التي تعلّمها النموذج أثناء التدريب، وكلما زاد عددها زادت قدرته على الفهم والاستنتاج.

256K
طول السياق

يقرأ نحو 262 ألف رمز دفعةً واحدة (ما يعادل كتابًا كاملًا). وفي هذا المشروع نستخدم 8 آلاف رمز لتوفير الذاكرة.

نص + صور
أنواع المدخلات

تفهم جميع النماذج في الدليل النصوص والصور معًا: صف له صورة، أو اسأله عن مستند أو جدول مصوَّر.

تفكير عميق
وضع الاستنتاج

تستطيع «التفكير» خطوة بخطوة قبل الإجابة عن الأسئلة الصعبة، ويمكنك تشغيل هذا الوضع أو إيقافه.

201 لغة ولهجة
دعم اللغات

تدعم نماذج Qwen3.5 أكثر من مئتي لغة ولهجة، ومنها العربية.

مفتوحة المصدر
الترخيص

يُنشر Qwen3.8-27B بترخيص Apache 2.0 الذي يسمح بالاستخدام المجاني، حتى في المشاريع التجارية.

🏆 الأقوى في هذا الدليل: Qwen3.8-27B

نموذج «كثيف» (Dense) يضم **27.3 مليار معامل** في 64 طبقة، ويجمع بين تقنيتَي Gated DeltaNet و Gated Attention.

نتائجه في اختبارات معروفة:



النتائج منشورة من فريق Qwen على صفحة النموذج الرسمية في **Hugging Face**، وتخص النسخة الكاملة غير المضغوطة.

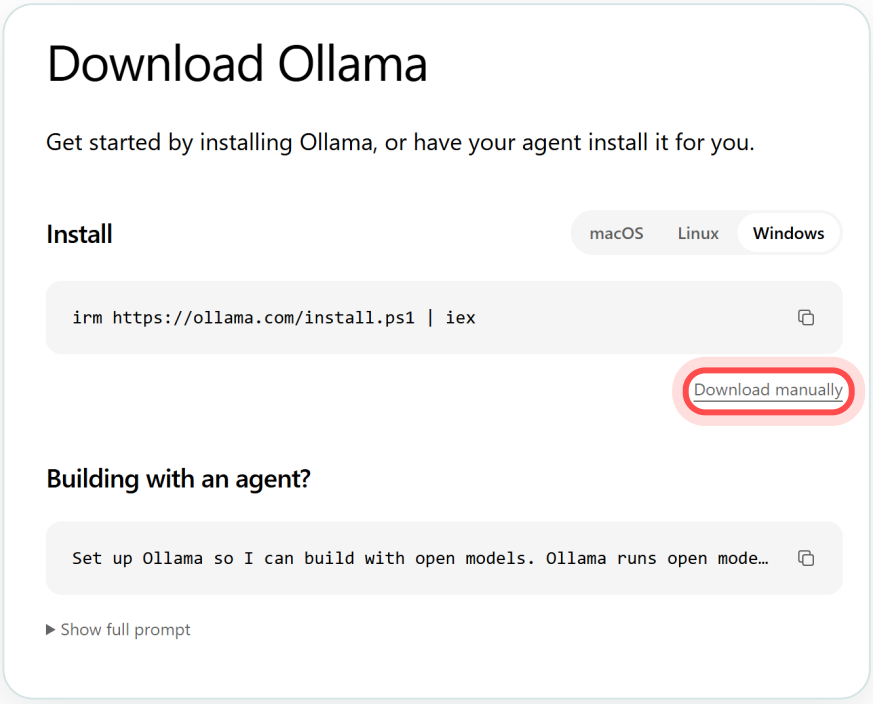
💾 **لماذا تعمل هذه النماذج على جهاز شخصي؟** لأن الأوامر في هذا الدليل تنزّل نسخًا مضغوطة (Q4) تُخزَّن فيها المعاملات بدقة 4 بت تقريبًا بدلًا من 16 بت؛ فينخفض حجم Qwen3.8-27B مثلًا من نحو 56 GB إلى نحو 17 GB، مع انخفاض طفيف في الدقة.

1 الخطوة الأولى

تثبيت برنامج Ollama

Ollama هو البرنامج الذي يشغّل نماذج الذكاء الاصطناعي على جهازك، وهو مجاني ورسمي.

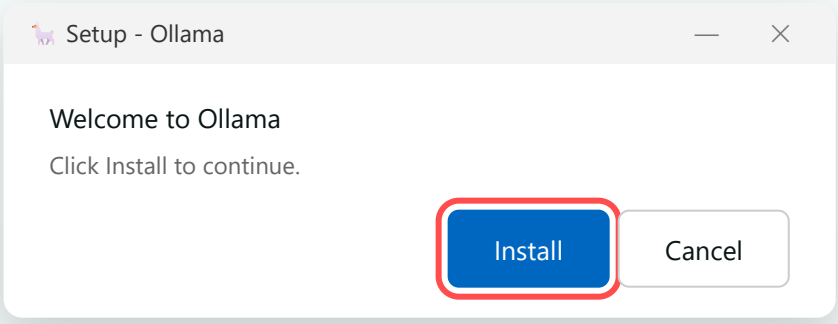
1. افتح الرابط التالي في المتصفح: **ollama.com/download**
2. اضغط على **Download manually** (المحدد باللون الأحمر 👇) لتنزيل ملف التثبيت **OllamaSetup.exe**.



صفحة التنزيل الرسمية لبرنامج Ollama

3. افتح الملف الذي نزّلته بالنقر عليه نقرًا مزدوجًا، ثم اضغط **Install** وانتظر حتى يكتمل التثبيت.

شكل توضيحي



✅ **تمّ بنجاح!** إذا ظهرت أيقونة Ollama 🦙 بجوار الساعة أسفل يمين الشاشة، فهذا يعني أن البرنامج يعمل.

2 الخطوة الثانية (أ)

اختر النموذج المناسب لجهازك

لا يحتاج كل جهاز إلى النموذج الأكبر. ابحث في الجدول عن حجم الذاكرة (RAM) في جهازك، واختر نموذجًا يناسبه. الجدول مرتّب من الأخف إلى الأثقل؛ فكلما نزلت كانت الإجابات أدق، لكن النموذج يحتاج إلى ذاكرة أكبر ويكون أبطأ.

النموذج	الشركة	الحجم	الذاكرة (RAM)	الصور	مناسب لـ
Qwen3.5-0.8B	Alibaba	1.3 GB	4 GB	✓	التجربة فقط (سريع، لكنه قد يخطئ في المعلومات)
Qwen3.5-2B	Alibaba	3 GB	8 GB	✓	الأسئلة البسيطة (دقة محدودة)
Qwen3.5-4B	Alibaba	4 GB	8 GB	✓	الحواسيب العادية
Gemma 4 E2B	Google	4.6 GB	8 GB	✓	الأجهزة الخفيفة
Gemma 4 E4B	Google	6.6 GB	12 GB	✓	الحواسيب العادية
⭐ **Qwen3.5-9B**	Alibaba	7 GB	16 GB	✓	معظم الاستخدامات بجودة عالية
Gemma 4 12B	Google	8 GB	16 GB	✓	توازن ممتاز بين السرعة والدقة
gpt-oss-20B	OpenAI	14 GB	16 GB	✗	التفكير والبرمجة
Qwen3.8-27B	Alibaba	17 GB	32 GB	✓	أعلى دقة في هذا الدليل
Gemma 4 26B	Google	18 GB	32 GB	✓	سريع رغم حجمه (MoE)
Gemma 4 31B	Google	20 GB	32 GB	✓	أعلى دقة من Google
Qwen3.6-35B-A3B	Alibaba	24 GB	Page File + 32 GB	✓	سريع رغم حجمه (MoE)

⭐ الخيار المقترح لأغلب الأجهزة الحديثة. نماذج Qwen من Alibaba Cloud، ونماذج Gemma من Google DeepMind، وgpt-oss من OpenAI. الأحجام حسب مكتبة **Ollama**.

ذاكرة جهازك 8 GB
اختر Qwen3.5-4B

ذاكرة جهازك 16 GB
اختر Qwen3.5-9B ⭐

ذاكرة جهازك 32 GB أو أكثر
اختر Qwen3.8-27B

🧠 **ما معنى MoE؟** نموذج لا يعمل من معاملاته في كل إجابة إلا جزء صغير (نحو 3-4 مليارات)، لذا يكون أسرع من حجمه، لكنه يحتاج إلى ذاكرة كافية لتحميله كاملًا. gpt-oss-20B لا يفهم الصور، وستنبّهك الواجهة إن أرفقت صورة أثناء استخدامه.

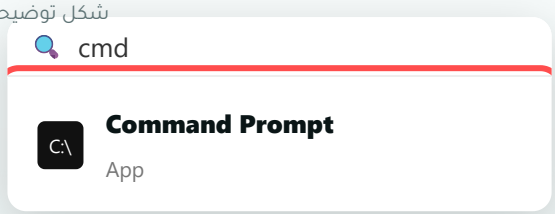
ℹ️ **ماذا عن Anthropic (Claude)؟** لا تتوفر حاليًا نماذج مفتوحة منها يمكن تشغيلها على الجهاز؛ إذ يعمل Claude عبر الإنترنت فقط.

2 الخطوة الثانية (ب)

نزّل النموذج الذي اخترته

1. اضغط زر Windows ⊞ في لوحة المفاتيح، واكتب **cmd**
2. افتح **Command Prompt**
3. انسخ أمر النموذج الذي اخترته من القائمة أدناه، والصقه فيه، ثم اضغط Enter

شكل توضيحي



`ollama pull qwen3.5:0.8b`	Qwen3.5-0.8B
`ollama pull qwen3.5:2b`	Qwen3.5-2B
`ollama pull qwen3.5:4b`	Qwen3.5-4B
`ollama pull gemma4:e2b-it-q4_K_M`	Gemma 4 E2B
`ollama pull gemma4:e4b-it-q4_K_M`	Gemma 4 E4B
`ollama pull qwen3.5:9b`	⭐ Qwen3.5-9B
`ollama pull gemma4:12b-it-q4_K_M`	Gemma 4 12B
`ollama pull gpt-oss:20b`	gpt-oss-20B
`ollama pull qwen3.8:27b-q4_K_M`	Qwen3.8-27B
`ollama pull gemma4:26b-a4b-it-q4_K_M`	Gemma 4 26B
`ollama pull gemma4:31b-it-q4_K_M`	Gemma 4 31B
`ollama pull qwen3.6:35b-a3b-q4_K_M`	Qwen3.6-35B-A3B

📋 حدّد سطر الأمر وانسخه بـ Ctrl+C، ثم الصقه في **Command Prompt** بالنقر بزر الفأرة الأيمن أو بـ Ctrl+V.



سيظهر شريط تنزيل كهذا: أبقِ النافذة مفتوحة حتى تظهر كلمة **success** في النهاية.

⚠️ **إذا توقف التنزيل** بسبب انقطاع الإنترنت، فالصق **الأمر نفسه** مرة أخرى، وسيُكمل من حيث توقف.

3 الخطوة الثالثة

تنزيل الواجهة من GitHub

هذه هي الواجهة التي تتحدث من خلالها مع النموذج، وهي تشبه ChatGPT لكنها تعمل على جهازك. ستنزّلها بثلاثة أوامر في **Command Prompt**.

1. افتح **Command Prompt** كما في صفحة 6 (أو استخدم النافذة نفسها التي نزّلت منها النموذج).
2. الصق الأوامر التالية **واحدًا تلو الآخر**، واضغط Enter بعد كل أمر:

أ. انتقل إلى مجلدك الشخصي

```
cd /d %USERPROFILE%
```

ب. نزّل المشروع من GitHub في ملف مضغوط باسم ai.zip

```
curl -Lo ai.zip https://github.com/mohammedmahdi0/offline-ai/archive/main.zip
```

ج. فُكّ ضغط الملف، فيظهر مجلد المشروع

```
powershell Expand-Archive ai.zip . -Force
```

✅ سيظهر مجلد جديد باسم **offline-ai-main** داخل مجلدك الشخصي (مثل **C:\Users\Ali**)، وهذا هو مجلد المشروع. **لا تنقله إلى مكان آخر**؛ لأن أمر التشغيل في الصفحة التالية يبحث عنه هنا.

💡 الأداتان **curl** و**powershell** موجودتان في Windows 10 وWindows 11، فلا تحتاج إلى تثبيت أي شيء إضافي. وإذا ظهرت رسالة خطأ أثناء التنزيل، فتأكد من اتصالك بالإنترنت وأعد الأمر نفسه.

4 الخطوة الرابعة

تشغيل الواجهة على نموذجك

بعد انتهاء التنزيل، شغّل الواجهة على نموذجك بأمرين في **Command Prompt**. وكرّر الأمرين نفسيهما في كل مرة تريد فيها استخدام البرنامج.

1. افتح **Command Prompt**: اضغط زر Windows ⊞، واكتب **cmd**، ثم اضغط Enter.
2. انتقل إلى مجلد المشروع بهذا الأمر، ثم اضغط Enter:

```
cd /d %USERPROFILE%\offline-ai-main
```

📋 انسخ الأمر كما هو؛ فالجزء **%USERPROFILE%** يتحوّل تلقائيًا إلى مجلدك الشخصي، أيًّا كان اسم المستخدم.

3. اكتب **أمر التشغيل**، ثم اضغط Enter. وهو يتكوّن من جزأين:

`qwen3.5:9b` اسم النموذج كما نزّلته بالأمر ollama pull	مسافة	`start.bat` ملف التشغيل: يشغّل Ollama ويفتح الواجهة

📋 أمر التشغيل لكل نموذج

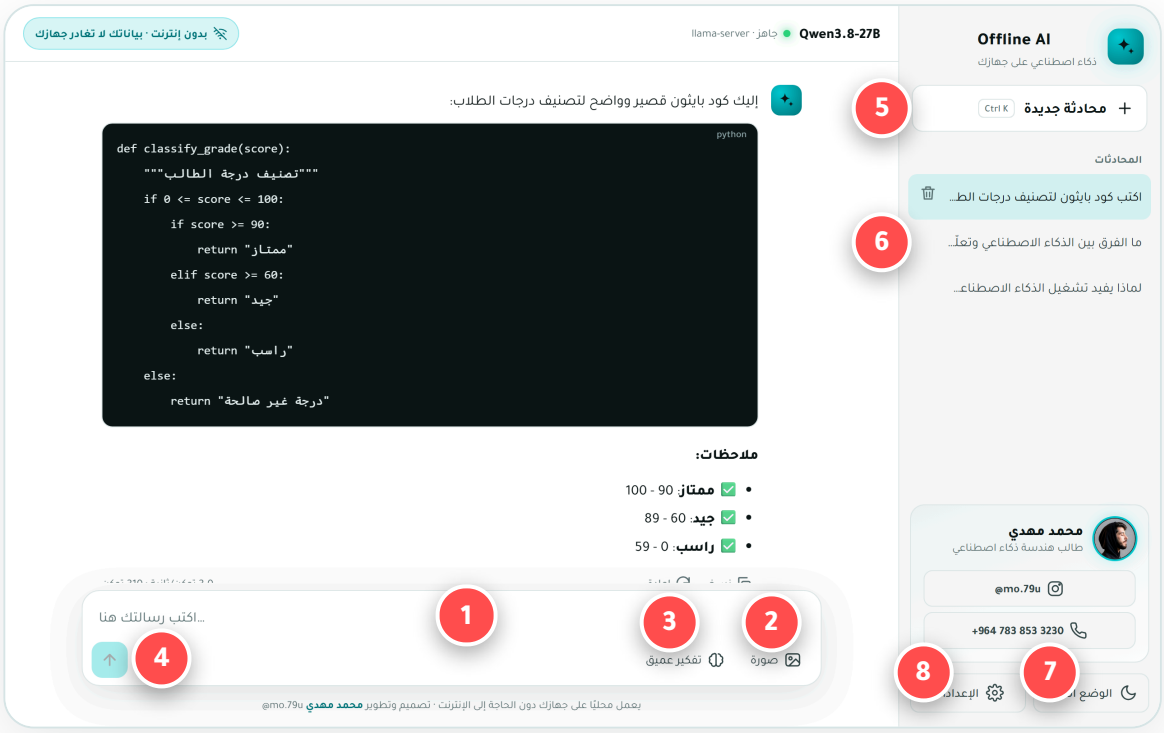
`start.bat qwen3.5:0.8b`	Qwen3.5-0.8B
`start.bat qwen3.5:2b`	Qwen3.5-2B
`start.bat qwen3.5:4b`	Qwen3.5-4B
`start.bat gemma4:e2b-it-q4_K_M`	Gemma 4 E2B
`start.bat gemma4:e4b-it-q4_K_M`	Gemma 4 E4B
`start.bat qwen3.5:9b`	⭐ Qwen3.5-9B
`start.bat gemma4:12b-it-q4_K_M`	Gemma 4 12B
`start.bat gpt-oss:20b`	gpt-oss-20B
`start.bat qwen3.8:27b-q4_K_M`	Qwen3.8-27B
`start.bat gemma4:26b-a4b-it-q4_K_M`	Gemma 4 26B
`start.bat gemma4:31b-it-q4_K_M`	Gemma 4 31B
`start.bat qwen3.6:35b-a3b-q4_K_M`	Qwen3.6-35B-A3B

✅ سيفتح المتصفح الواجهة والنموذج جاهز 🎉 وتبقى **نافذة سوداء** مفتوحة: **لا تغلقها** ما دمت تستخدم البرنامج. وإذا كتبت اسم نموذج لم تنزّله، فستظهر قائمة النماذج الموجودة على جهازك.

5 الخطوة الأخيرة

طريقة الاستخدام والتبديل بين النماذج

اكتب سؤالك بالعربية واضغط Enter، وسيظهر الجواب كلمةً كلمة.



1. **مربع الكتابة**: اكتب سؤالك هنا
2. **صورة**: ارفع صورة واسأل عنها (أو اسحبها إلى الصفحة)
3. **تفكير عميق**: أبطأ، لكنه أدق في الأسئلة الصعبة
4. **إرسال**: ويتحوّل إلى زر **إيقاف** أثناء الكتابة
5. **محادثة جديدة**: لبدء موضوع جديد
6. **المحادثات**: جميعها محفوظة، ويمكنك العودة إليها متى شئت
7. **الوضع الفاتح والداكن**
8. **الإعدادات**: لتغيير النموذج والتعليمات

التبديل بين النماذج

1. اضغط زر **الإعدادات** (رقم 8).
2. من قائمة **النموذج** اختر أي نموذج نزّلته (المحددة بالأحمر).
3. اضغط **حفظ**، وستستخدم المحادثات التالية النموذج الجديد.



السرعة: تظهر تحت كل إجابة بعدد الرموز في الثانية. وإذا كانت الإجابة بطيئة جدًا، فاختر نموذجًا أصغر، أو تأكد أنك فتحت الواجهة على النموذج الصحيح (صفحة 8).

للحصول على أفضل سرعة

اجعل النموذج أسرع

لا تعتمد السرعة على طريقة التشغيل، بل على **حجم النموذج مقارنةً بذاكرة بطاقة الرسوميات** (VRAM). فإذا اتسعت له الذاكرة كتب الإجابة فورًا تقريبًا، وإذا كان أكبر منها نُقل جزء من العمل إلى المعالج فأصبح بطيئًا جدًا.

قياس فعلي على حاسوب محمول

بطاقة رسوميات RTX 4070 بذاكرة 8 GB، وذاكرة 32 GB، والسؤال: «اكتب لي كود بايثون لتصنيف درجات الطلاب».

النموذج	السرعة	النتيجة
Qwen3.5-0.8B	نحو **140** رمزًا في الثانية	كتب الإجابة كاملة في ثوانٍ.
Qwen3.8-27B	نحو **3** رموز في الثانية	استغرق رد قصير نحو دقيقة ونصف؛ لأن حجمه (17 GB) أكبر بكثير من ذاكرة البطاقة.
Qwen3.6-35B-A3B	–	لم يعمل دون تفعيل Page File في Windows.

كيف أعرف ذاكرة بطاقة الرسوميات؟ افتح **Task Manager** بالضغط على Ctrl + Shift + Esc، ثم **Performance** ثم **GPU**، وانظر إلى **Dedicated GPU memory**. وللحصول على أعلى سرعة، اختر نموذجًا حجمه (في جدول صفحة 5) أصغر من هذا الرقم.

طريقة أخرى: النقر المزدوج

يمكنك أيضًا النقر نقرًا مزدوجًا على ملف **start.bat** في مجلد المشروع، فتُفتح الواجهة على آخر نموذج اخترته.

وقد يظهر عندها تحذير أزرق بعنوان **Windows protected your PC**؛ فاضغط **More info** ثم **Run anyway**. يظهر هذا التحذير مع أي ملف جديد منزَّل من الإنترنت، **ولا يعني أن الملف ضار**.

لماذا لا أحادث النموذج داخل Command Prompt بالأمر ollama run؟ لأن **Command Prompt** لا يعرض الحروف العربية بشكل صحيح، فتظهر متقطعة. أما الواجهة فتعرضها كاملة، وبالسرعة نفسها.

🛠️ عند حدوث مشكلة

حل المشكلات الشائعة

المشكلة	الحل
توقف التنزيل وظهرت رسالة خطأ	الصق أمر التنزيل نفسه مرة أخرى، وسيُكمل من حيث توقف.
رسالة 'ollama' is not recognized	أغلق **Command Prompt** وافتحه من جديد. وإن لم ينجح ذلك، فأعد تشغيل الجهاز.
خطأ في الذاكرة (يحتوي على memory أو allocate)	اختر نموذجًا أصغر من جدول صفحة 5. وإن أردت Qwen3.8-27B تحديدًا، فشغّل **start-lowmem.bat** بدلًا من **start.bat**.
ظهور رسالة «Ollama غير مشغَّل»	شغّل **start.bat** مرة أخرى (فهو يشغّل Ollama تلقائيًا)، أو افتح Ollama من قائمة «ابدأ».
ظهور رسالة «لا يوجد نموذج»	لم تنزّل أي نموذج بعد؛ انسخ أمر التنزيل من صفحة 6.
ظهور رسالة «النموذج قيد التحميل...»	انتظر من 20 إلى 60 ثانية؛ فالتشغيل الأول يستغرق بعض الوقت.
الإجابة بطيئة جدًا	النموذج أكبر من ذاكرة بطاقة الرسوميات؛ فاختر نموذجًا أصغر (صفحة 10)، وأوقف «التفكير العميق».
جهازي أضعف من المطلوب	نزّل نموذجًا أصغر من جدول صفحة 5، ثم اختره من ⚙️ «الإعدادات».

إذا ظهر خطأ في ذاكرة بطاقة الرسوميات حتى مع **start-lowmem.bat**، فشغّل الأمر التالي لتخفيف الحمل عنها:

```
> start-lowmem.bat -GpuLayers 10
```

📋 افتح **Command Prompt**، وانتقل إلى مجلد المشروع بالأمر **cd** (صفحة 8)، ثم الصق الأمر

❓ أسئلة شائعة

هل يحتاج البرنامج إلى الإنترنت بعد التثبيت؟

لا. بعد تنزيل كل شيء، يمكنك قطع الاتصال بالإنترنت وسيعمل بشكل طبيعي.

هل يوجد حد للرسائل أو اشتراك؟

لا. البرنامج مجاني بالكامل ودون حدود، لكن يُفضَّل بدء محادثة جديدة إذا طالت المحادثة كثيرًا.

هل تُرسَل محادثاتي إلى أي جهة؟

لا. النموذج والمحادثات جميعها على جهازك فقط.

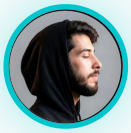
كيف أغلق البرنامج؟

أغلق المتصفح والنافذة السوداء. وفي المرة القادمة، شغّل أمر التشغيل نفسه (صفحة 8) فقط، دون الحاجة إلى تنزيل أي شيء من جديد.

تهانينا 🎉

أصبح لديك ذكاء اصطناعي خاص بك يعمل دون إنترنت.

إذا استفدت من هذا الدليل، فتابعني على Instagram؛ أشارك فيه أدوات الذكاء الاصطناعي ونصائحه بأسلوب مبسّط.



محمد مهدي

طالب هندسة ذكاء اصطناعي · مطوّر Offline AI

Instagram · @mo.79u

WhatsApp · +964 783 853 3230

© 2026 محمد مهدي – جميع حقوق الدليل والتصميم محفوظة. المشروع مفتوح المصدر بموجب رخصة MIT، ويجب الإبقاء على حقوق المطوّر عند نشره أو تعديله.

Ollama وQwen علامتان تجاريتان لمالكيهما، وهذا المشروع مستقل وغير تابع لهما. تُنزَّل النماذج من مكتبة Ollama الرسمية وتخضع لتراخيصها.